


Detección automática de contradicciones normativas


Carlos Sinai Unda Miguel

Prototipo mínimo: dado un par de fragmentos normativos, clasificar su relación como contradiction, entailment o neutral.

Tarea mínima



Arquitectura mínima del prototipo



Modelo

- Qwen/Qwen2.5-0.5B-Instruct

Datos

- 9 pares normativos sintéticos (data/cases.jsonl)
- 4 contradiction · 2 entailment · 3 neutral
- No citan normas reales: evita atribuir texto falso

Relación con Semanas 1, 2 y 3

SEMANA 1

Causalidad

- Decoder causal: no ve tokens futuros
- Norma A y B se concatenan en un solo input
- El orden de lectura importa para la atención

SEMANA 2

Logits y decoding

- logits -> softmax -> distribución
- greedy: determinista, siempre argmax
- sampling ($T=0.8$, $\text{top}_p=0.9$): explora, inestable

SEMANA 3

Salida estructurada

- JSON exacto -> recuperable -> schema-valid
- Validación estructural $\neq$ validación semántica
- reason puede acertar el criterio y label fallar

Prompt y salida estructurada

P0 -> P1: qué cambió

- P0 (baseline): instrucción corta, sin criterios explícitos
- P1 (mejorado): agrega definición de cada label
- P1 separa contexto como “no instrucción”
- P1 fuerza formato JSON exacto, sin texto extra

```
{ "label": "contradiction",  
  "confidence": 0.82,  
  "reason": "..."} 
```

Tres niveles de validez

1

JSON parseable

El texto generado se puede leer como objeto JSON (aunque venga envuelto en ``json`).

2

Schema-valid

Cumple el JSON Schema: enum de label, confidence en [0,1], reason 1-300 caracteres.

3

Semánticamente correcto

label == gold. Un JSON válido puede seguir siendo incorrecto.

Tres experimentos, una variable a la vez

Exp. 1 — Prompt

Variable modificada

P0 vs P1

Se mantiene fijo

modelo, casos, contexto C0, decoding greedy

Exp. 2 — Contexto

Variable modificada

C0 (neutral) vs C1 (conflictivo)

Se mantiene fijo

modelo, prompt P1, casos, decoding greedy

Exp. 3 — Decoding


Variable modificada

greedy vs sampling (T=0.8, top_p=0.9, 5 runs)

Se mantiene fijo

modelo, prompt P1, contexto C0, casos

Resultados y caso fallido



Caso fallido — id 1 (contradiction)

Exp. 3, mismo prompt/contexto/caso, 5 corridas con sampling:

run 0	neutral
run 1	contradiction
run 2	contradiction
run 3	neutral
run 4	JSON truncado (sin cierre)

3 causas visibles: cambio de etiqueta entre greedy y sampling, inestabilidad entre corridas (estabilidad media = 0.622) y truncamiento por max_new_tokens=150.

Limitación y conclusión

Limitaciones

- 9 casos sintéticos
- No hay jerarquía normativa ni vigencia temporal modelada
- Qwen2.5-0.5B es débil en razonamiento jurídico en español

Conclusión

En estos 9 casos, mejorar el prompt (P0 -> P1) y variar el contexto (C0 -> C1) no cambiaron las métricas: el modelo colapsa a “neutral” en ambos casos con greedy. El cambio real llegó del decoding: sampling subió la accuracy de 0.222 a 0.356, al costo de una estabilidad de solo 0.622. El cuello de botella no es el prompt ni el contexto, es la capacidad del modelo de 0.5B para aplicar el criterio que ya sabe verbalizar en su propio campo reason.